1 III. Tiền xử lý NLP

1.1 Giới thiệu chung

Phần này trình bày chi tiết quy trình xử lý ngôn ngữ tự nhiên, từ việc phân tích đặc điểm tập dữ liệu thô đến việc áp dụng các kỹ thuật tiền xử lý nâng cao và vector hóa nhằm tối ưu hóa hiệu suất cho các mô hình học máy.

1.2 Tập dữ liệu

Nghiên cứu sử dụng tập dữ liệu **20newsgroups**, bao gồm khoảng 18.000 bài đăng thuộc 20 chủ đề khác nhau. Tập huấn luyện với hơn 11.000 mẫu được sử dụng chính, với sự phân bổ các lớp tương đối đồng đều.

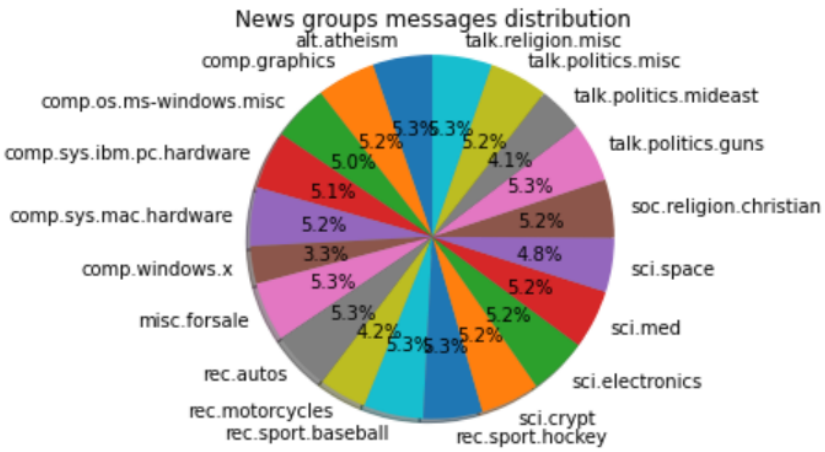

Hình 1: Biểu đồ phân phối các nhóm tin tức.

1.3 Phân tích Thống kê văn bản

1.3.1 Độ dài văn bản

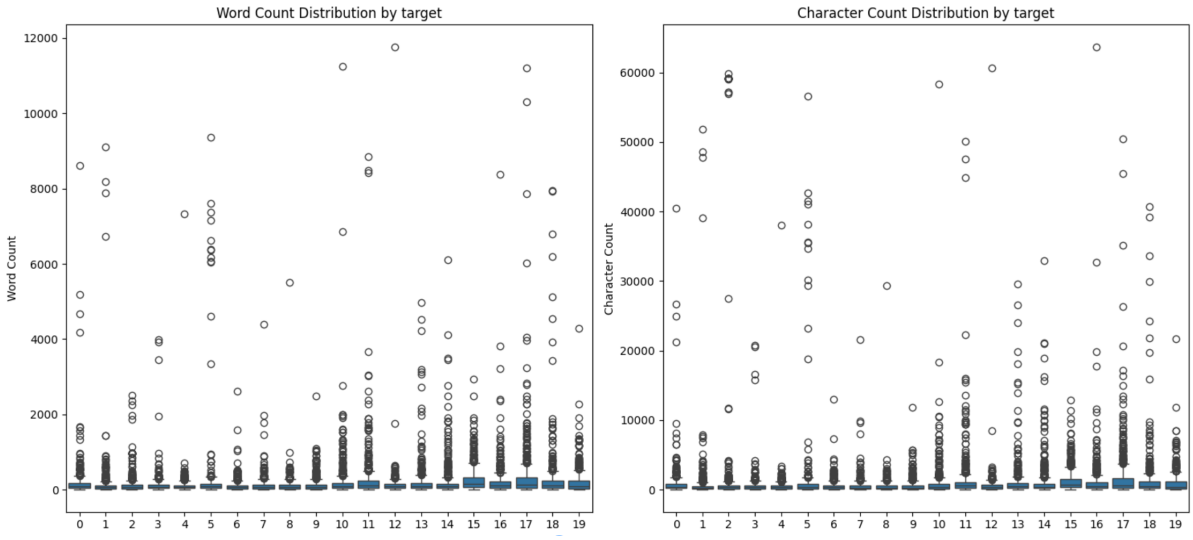

Hình 2: Phân phối độ dài từ (Word Count) và ký tự (Character Count) theo nhãn mục tiêu.

Nhận xét: Mỗi văn bản chứa trung bình từ 100 - 200 từ và 500 - 1000 kí tự. Tuy nhiên, có một số lượng không nhỏ ngoại lệ có thể chứa hơn 6000 từ và 40000 kí tự, chứng tỏ sự đa dạng và phức tạp của tập ngữ liệu.

Kiểm định MannWhitney U test: Kiểm tra Mann-Whitney U được sử dụng để so sánh sự khác biệt giữa hai nhóm độc lập khi biến phụ thuộc là thứ tự hoặc liên tục, nhưng không phân phối chuẩn. Đây là Kiểm định phi tham số (Nonparametric Tests) được sử dụng trong những trường hợp dữ liệu không có phân phối chuẩn, hoặc cho các mẫu nhỏ có ít đối.

Kết quả: Kiểm định Mann-Whitney U cho thấy 72% cặp phân lớp có sự khác biệt đáng kể về phân phối độ dài cả về ký tự và về từ. Điều này cho thấy sự phân bố phân tán về mặt độ dài ngữ liệu, và nó có thể trở thành một đặc trưng quan trọng cho các bài toán phân lớp trên tập dữ liệu này.

1.3.2 Word cloud và TTR

Chỉ số **Type-Token Ratio (TTR)** dùng để đánh giá độ phong phú từ vựng, trong phổ điểm từ 0 đến 1 (càng cao càng chứng tỏ phong phú). Không có một ngưỡng TTR chuẩn để kết luận chắc chắn rằng vốn từ phong phú hay không. TTR chỉ là tỉ lệ giữa số từ khác nhau và tổng số từ, nhưng nó phụ thuộc rất mạnh vào độ dài văn bản: văn bản càng dài thì TTR thường càng giảm. Mà dựa vào phân phối độ dài ở trên, đa số các target có sự khác biệt về độ dài văn bản giữa chúng, vì vậy rất khó đánh giá công bằng về TTR.

Word Cloud (đám mây từ) là một cách trực quan hóa văn bản, trong đó: Từ xuất hiện càng nhiều → hiển thị càng to. Nó giúp nhìn nhanh những từ quan trọng hoặc phổ biến trong một tập dữ liệu văn bản. Ở đây, kĩ thuật WordCloud được tinh chỉnh để loại bỏ những từ mang chức năng ngữ pháp mà không mang ý nghĩa văn bản, nhờ đó hiển thị các từ quan trọng nhất của chủ đề đó.

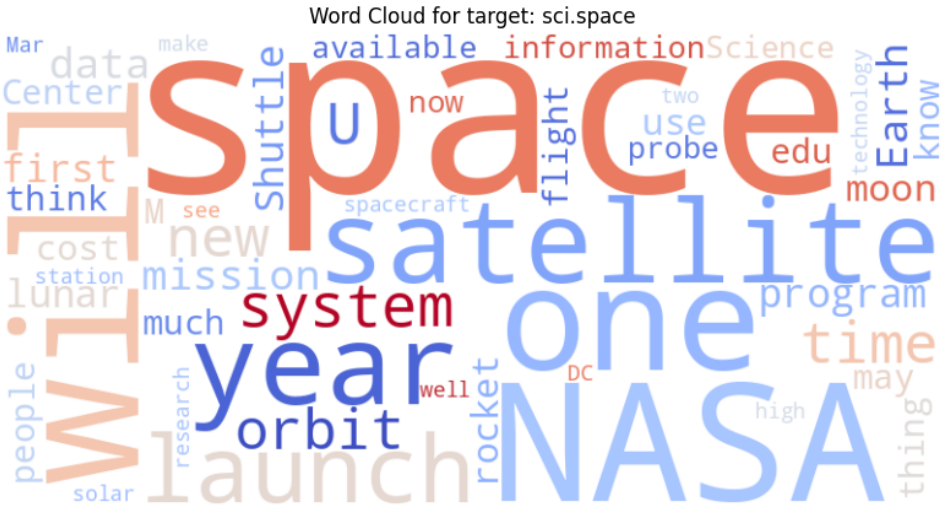

Hình 3: Trực quan hóa Word Cloud cho chủ đề sci.space.

1.3.3 Phân phối Zipf

Phân phối Zipf's mô tả hiện tượng trong ngôn ngữ: Tần suất của từ tỉ lệ nghịch với thứ hạng của nó.

Log–log plot là đồ thị mà cả trục x và trục y đều ở thang logarit. Mối quan hệ giữa Log–log plot và Zipf : Nếu dữ liệu tuân theo Zipf: Vẽ: trục x: log(rank), trục y: log(frequency), Đồ thị sẽ thấy gần như đường thẳng.

Kết quả thực nghiệm trên đồ thị Log-log cho thấy tập dữ liệu tuân thủ định luật Zipf với đường thẳng có hệ số góc xấp xỉ -1, minh chứng cho tính tự nhiên của ngôn ngữ trong bộ dữ liệu này. Điều này phản ánh đặc trưng phổ biến của ngôn ngữ tự nhiên, trong đó một số ít từ xuất hiện rất thường xuyên, trong khi phần lớn các từ xuất hiện rất hiếm.

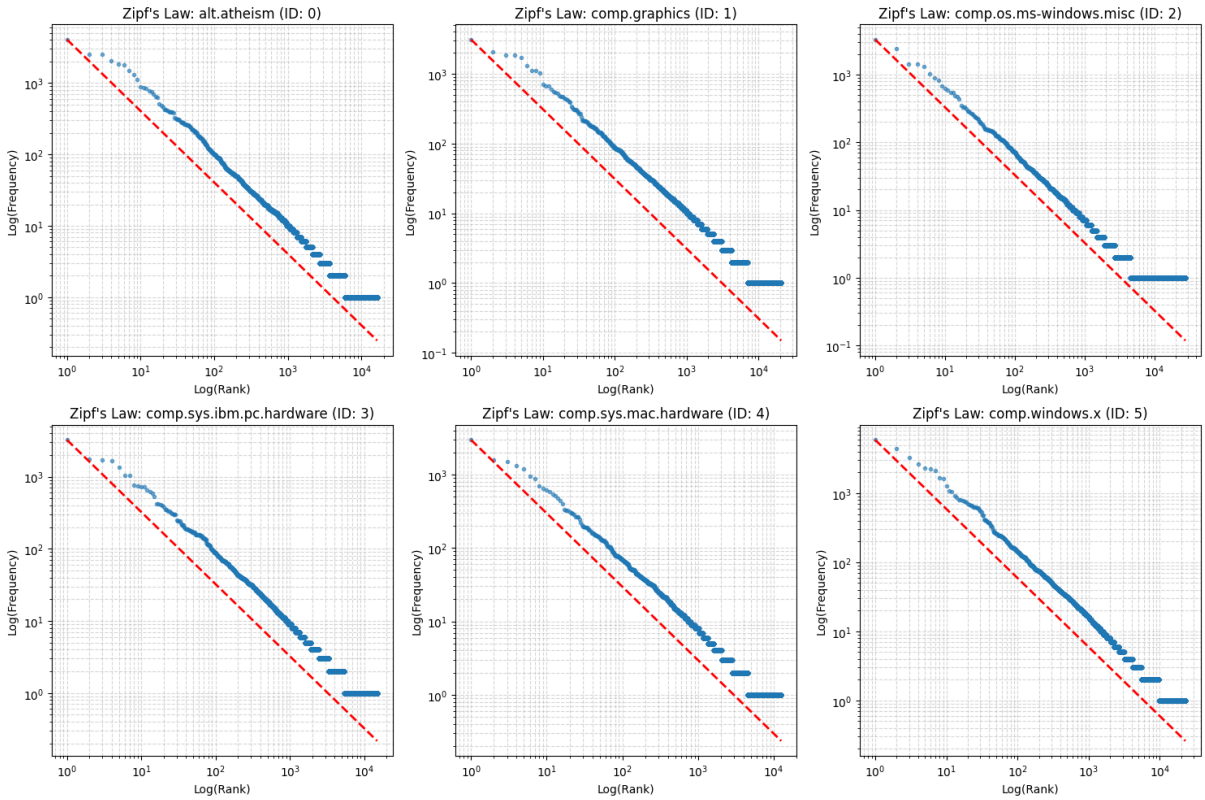

Hình 4: Đồ thị Log-log kiểm chứng định luật Zipf trên một số phân lớp.

1.4 Các kĩ thuật tiền xử lý

1.4.1 Pipeline chuẩn hóa văn bản

Pipeline bao gồm các bước: làm sạch mã HTML/URL, loại bỏ ký tự đặc biệt, chuẩn hóa chữ thường và khoảng trắng. *Kết quả:*

- Số từ gốc: 211123
- TTR gốc: 0.1004
- Số từ sau chuẩn hóa: 86850
- TTR sau chuẩn hóa: 0.0436
- Giảm số lượng từ: 58.86%
- Giảm độ dài văn bản: 5.27%
- Phân lớp giảm độ dài nhiều nhất: Phân lớp 10

Diễn giải và phân tích kết quả:

- *Giảm nhiễu đáng kể:* Pipeline tiền xử lý nâng cao—loại bỏ thẻ HTML, URL, các ký hiệu mạng xã hội và ký tự không phải chữ cái—đã làm giảm số lượng từ vựng duy nhất tới 58.86%.

- *Thay đổi mật độ từ vựng:* Tỷ lệ TTR giảm tương đối 56.57%. Điều này cho thấy quá trình làm sạch đã gộp các biến thể dư thừa (ví dụ: chuyển về chữ thường) và loại bỏ các token thưa, không mang tính ngôn ngữ.

- *Chuẩn hóa độ dài văn bản:* Độ dài trung bình của tài liệu trên toàn bộ tập dữ liệu giảm 5.27%. Tuy nhiên, một số nhóm như *rec.sport.hockey* (target 10) giảm mạnh hơn, tới 20.68%, cho thấy sự tập trung của dữ liệu không tiêu chuẩn trong các nhóm cụ thể.

- *Ảnh hưởng đến phân phối:* Mặc dù giá trị trung vị về số từ và số ký tự giảm ở cả 20 nhóm, độ lệch chuẩn nhìn chung cũng giảm, dẫn đến cấu trúc dữ liệu đồng đều hơn.

1.4.2 So sánh chiến lược tokenization

Tokenization là quá trình chia nhỏ một đoạn văn bản dài thành các đơn vị nhỏ hơn gọi là tokens. Đây là một bước tiền xử lý cần thiết và cực kỳ quan trọng trong NLP, giúp cho máy tính có thể phân tích, vector hóa và hiểu được ý nghĩa của ngôn ngữ.Các phương pháp tokenization phổ biến bao gồm:

- **Sentence-level Tokenization (cấp độ câu):** chia một đoạn văn hoặc văn bản thành các câu riêng biệt.

- **Word-level Tokenization (cấp độ từ):** Đây là cách tiếp cận truyền thống và phổ biến nhất, coi mỗi từ là một token.

- **Character-level Tokenization (cấp độ ký tự):** chia ngữ liệu thành các ký tự riêng biệt.

- **Subword Tokenization:** Đây là phương pháp phổ biến nhất đối với các mô hình LLM hiện nay như GPT, BERT. Các từ phổ biến được giữ nguyên, còn các từ hiếm hoặc phức tạp sẽ bị băm nhỏ thành các cụm ký tự có nghĩa (prefixes, suffixes, roots). Ví dụ: "unfriendly"→ ["un", "friend", "ly"]. Một số thuật toán phổ biến: Byte Pair Encoding (BPE), WordPiece, SentencePiece. Ở đây, em đã dùng BPE của Hugging Face để so sánh.

category	words_vocab_size	words_avg_len	words_oov_rate	bpe_vocab_size	bpe_avg_len	bpe_oov_rate	sentences_vocab_size	sentences_avg_len	sentences_oov_rate	chars_vocab_size	chars_avg_len	chars_oov_rate
alt.atheism	8991	190.58	0.3285	9105	200.11	0.2367	963	2.04	0.9829	27	1061.86	0.0
comp.graphics	10299	148.26	0.1981	9637	163.59	0.1172	973	1.68	0.9119	27	862.86	0.0
comp.os.ms-windows.misc	18307	126.79	0.3214	9609	236.49	0.2038	1173	2.01	0.9752	27	1061.94	0.0
comp.sys.ibm.pc.hardware	7051	123.73	0.2803	7116	130.74	0.2049	1081	1.88	0.9865	27	657.18	0.0
comp.sys.mac.hardware	6334	104.27	0.2583	6583	109.74	0.1989	956	1.68	0.9831	27	559.44	0.0
comp.windows.x	11481	221.24	0.2599	9861	245.29	0.1161	1309	2.66	0.9268	27	1277.18	0.0
misc.forsale	8304	90.03	0.3065	8144	99.45	0.1970	780	1.36	0.9785	27	513.39	0.0
rec.autos	8073	112.17	0.2954	8089	119.61	0.2036	981	1.68	0.9903	27	604.32	0.0
rec.motorcycles	8255	103.82	0.2837	8215	111.72	0.1918	994	1.69	0.9689	27	551.47	0.0
rec.sport.baseball	7193	109.16	0.3025	7211	117.33	0.2170	1033	1.75	0.9953	27	585.78	0.0
rec.sport.hockey	9993	160.12	0.2595	9260	175.49	0.1530	1178	2.00	0.9951	27	897.53	0.0
sci.crypt	12529	264.56	0.2307	11979	280.64	0.1367	1106	1.92	0.9831	27	1541.41	0.0
sci.electronics	8384	123.65	0.2882	8312	131.76	0.1959	945	1.62	1.0000	27	678.23	0.0
sci.med	12977	191.52	0.3039	11828	210.55	0.1508	1062	1.82	0.9906	27	1121.39	0.0
sci.space	12884	192.89	0.2859	11814	209.08	0.1626	964	1.64	0.9947	27	1136.81	0.0
soc.religion.christian	11850	258.28	0.2886	11005	271.29	0.1486	1407	2.38	0.9960	27	1412.24	0.0
talk.politics.guns	11424	207.93	0.2564	11227	225.11	0.1606	1018	1.88	0.9900	27	1181.06	0.0
talk.politics.mideast	14646	341.53	0.2444	12570	364.76	0.1220	1652	2.99	0.9192	27	1930.50	0.0
talk.politics.misc	10684	278.83	0.2708	10555	291.47	0.1781	1427	3.15	0.9850	27	1565.20	0.0
talk.religion.misc	9115	218.62	0.2746	9148	231.83	0.1839	793	2.14	0.9926	27	1209.40	0.0

Hình 5: Kết quả so sánh chi tiết các chỉ số giữa các phương pháp Tokenization.

Phân tích và diễn giải kết quả:

- *So sánh tỷ lệ OOV:*
  - **Cấp độ câu:** Tỷ lệ OOV cực cao (gần 100%), đơn giản vì các chuỗi câu chính xác hiếm khi lặp lại trên các tập dữ liệu.
  - **Cấp độ ký tự:** Tỷ lệ OOV là 0,0%, nhưng có độ dài chuỗi trung bình cao nhất (dao động từ 500 đến hơn 1.900 tokens mỗi tài liệu).
  - **Cấp độ từ:** Tỷ lệ OOV cao (19-32% trong các mẫu ban đầu), cho thấy khả năng tổng quát hóa kém đối với từ vựng mới.
  - **BPE:** Giảm thành công tỷ lệ OOV xuống gần một nửa so với cấp độ từ.
- *Đánh đổi về hiệu quả:* Các chuỗi BPE dài hơn một chút so với chuỗi cấp độ từ do việc chia nhỏ thành subword, nhưng vẫn gọn nhẹ hơn đáng kể so với chuỗi cấp độ ký tự, mang lại sự cân bằng tốt nhất cho hiệu quả tính toán.
- *Tính nhất quán của tập dữ liệu:* Các quy luật về OOV và độ dài chuỗi đồng nhất trên tất cả 20 danh mục của tập dữ liệu 20newsgroups, xác nhận rằng các đặc điểm tokenization này không phụ thuộc vào từng danh mục cụ thể.
- *Lợi thế của Subword:* Đối với các tác vụ liên quan đến thuật ngữ chuyên môn hoặc văn bản trên mạng xã hội (như tập dữ liệu 20newsgroups), BPE vượt trội vì nó vẫn có thể biểu diễn các từ chưa có trong từ điển bằng cách kết hợp các thành phần con đã biết.

Kết luận: Phương pháp Subword là phương pháp tốt nhất cho các tác vụ huấn luyện mô hình NLP. Tuy nhiên, vì bài này tập trung vào tiền xử lý nên em vẫn sẽ chọn phương pháp Word-level tokenization do nó dễ sử dụng và đảm bảo khả năng diễn giải kết quả cho các tác vụ sau. *Hướng phát triển:* Khám phá các phương pháp tokenization khác như WordPiece, SentencePiece để ứng dụng vào bài toán phân lớp văn bản hoặc mô hình ngôn ngữ.

1.4.3 Loại bỏ stop words và phân tích thông tin

Stop word (từ dừng): là những từ xuất hiện cực kỳ phổ biến trong ngôn ngữ nhưng lại mang rất ít ý nghĩa về mặt nội dung hoặc ngữ cảnh đặc trưng cho một văn bản. Ví dụ tiếng Anh: the, is, at, which, on, and... Việc loại bỏ từ dừng mang ý nghĩa lọc bỏ các từ không cần thiết để tập trung vào những từ khóa quan trọng.

Kết quả:

- Tỷ lệ kích thước bộ từ vựng sau / trước: 0.496
- Số từ vựng giảm hơn một nửa, cho thấy tỷ lệ từ dừng trong các văn bản tin tức là cực nhiều.

Mutual Information (trong phân lớp) đo lường lượng thông tin mà một biến đầu vào X chứa đựng về lớp đó. Theo nghĩa đơn giản, nếu ta biết giá trị của biến đầu vào X, bạn sẽ có thêm bao nhiêu thông tin về biến phân lớp Y.

Kết quả: Đối với chỉ số MI, việc giảm stop word có vẻ không hiệu quả khi chỉ số MI thậm chỉ **giảm -13.47%**. Điều này cho thấy ít nhất với CountVectorizer (một phương pháp vector hoá đơn giản), việc loại bỏ stop word có thể làm giảm sự tương quan giữa

văn bản và lớp, do sự thiếu mạch lạc về mặt ngữ pháp khi stop word không còn. Tuy nhiên, kết quả có thể khác nếu dùng các vector hoá khác. Vì vậy, cần các bài toán thực tế (như Naive-Bayes) để đánh giá chính xác tác động của stop word.

Naive_Bayes: Là một phương pháp phân loại dựa trên thống kê, giả định ngây thơ rằng các đặc trưng là độc lập với nhau. Tuy đơn giản hoá quá mức, nó hoạt động tương đối ổn trên các bài toán dữ liệu nhiều chiều, bài toán lọc email spam nơi không yêu cầu nhiều mẫu huấn luyện.

- Đối với bài toán phân lớp này, đầu tiên ngữ liệu sẽ được vector hoá (kĩ thuật này sẽ được nhắc đến sau) bằng CountVectorizer hoặc TF-IDF (một lựa chọn vector hoá phức tạp hơn, tính tới độ đặc biệt của một từ trong một phân lớp nhất định), sau đó tính toán phân lớp dựa vào công thức Bayes.
- Kết quả sẽ được so sánh giữa 2 cách phân loại này, từ đó chọn được phương pháp vector hoá hợp lý nhất.

Bảng 1: So sánh hiệu suất phân loại Naive Bayes khi xử lý Stop words.

Phương pháp	**Dữ liệu**	**Accuracy**	**F1-Score**
TF-IDF	Có Stop Words	0.6708	0.6459
	Không Stop Words	**0.7097**	**0.6842**
CountVectorizer	Có Stop Words	0.6390	0.6305
	Không Stop Words	0.6580	0.6485

Phân tích kết quả:

- Đối với cả hai phương pháp Vector hoá, kết quả phân lớp đều nghiêng một chút về phía **ngữ liệu đã loại bỏ stop words**. Điều này chứng tỏ sự hiệu quả của phương pháp tiền xử lý này, tuy còn hạn chế.
- Khi so sánh giữa hai phương pháp vector hoá, ta thấy **TFIDF đạt kết quả tốt hơn**. Điều này là do việc đánh trọng số dựa trên độ hiếm của từ, dẫn đến từ xuất hiện nhiều nhưng phổ biến sẽ bị hạ thấp giá trị. Điều này cực kì phù hợp với việc loại bỏ stop-words.

Kết luận: Khi loại bỏ stop-words, nên kết hợp với TF-IDF trong các bài toán phân lớp nhằm đảm bảo hiệu quả của việc loại bỏ những từ phổ biến trong mọi lớp. *Hướng phát triển:* Xây dựng danh sách stop words tùy chỉnh (domain-specific) để tránh loại bỏ nhầm các từ có giá trị phân loại cao trong các nhóm tin tức chuyên biệt.

1.4.4 Stemming, Lemmatization và so sánh định lượng

Định nghĩa: Stemming và Lemmatization là hai kỹ thuật quan trọng dùng để chuẩn hóa văn bản. Mục tiêu chung của chúng là đưa các biến thể của một từ (ví dụ: "walking", "walked", "walks") về cùng một dạng gốc để máy tính dễ dàng xử lý và thống kê.

- **Stemming**: thường đề cập đến một quy trình lược bỏ thô sơ, cắt bỏ phần cuối của từ, thường bao gồm việc loại bỏ các hậu tố phái sinh.

- **Lemmatization**: thực hiện các bước cắt gọn một cách chính xác bằng cách sử dụng từ vựng và phân tích cấu trúc của từ, thường nhằm mục đích trả về dạng gốc hoặc dạng từ điển của từ.

So Sánh:

- Tốc độ: Stemming nhanh hơn nhiều do lemmatization phải truy cập vào từ điển để tìm từ.
- Độ chính xác: Lemmatization tốt hơn nhiều so với stemming, do tiếp cận vào bản chất từ vựng.
- Ví dụ: gặp từ "saw", việc stemming có thể chỉ trả về "s", trong khi việc lemmatization sẽ cố gắng trả về "see"hoặc "saw"tùy thuộc vào việc từ đó được sử dụng như một động từ hay một danh từ (có thể dựa vào POS (Part-of-speech)).
- Stemming dễ gây ra lỗi Over-stemming (gộp các từ khác nghĩa vào cùng một gốc) hoặc Under-stemming (không gộp được các từ cùng nghĩa).

Collision rate: là tỉ lệ các từ khác nhau bị trả về cùng một gốc. Điều này đánh giá mức độ tác động của các phương pháp rút gọn từ đối với ngữ liệu.

Kết quả: Collision rate ở **Lemmatizer là thấp nhất** (0.06 so với 0.2 của Stemming), điều này là hợp lý xét về cách thức rút gọn từ.

- Stemming rút gọn từ dựa cứng nhắc vào quy tắc, vì vậy nhiều từ khác nghĩa bị đưa về chung một gốc dù chúng có thể mang ý nghĩa khác hoàn toàn, thậm chí từ rút gọn có thể hoàn toàn vô nghĩa.
- Lemmatization rút gọn dựa vào từ điển, vì vậy tránh được việc sinh ra những từ vô nghĩa, giảm tỉ lệ collision rate.

Logistic regression: là một thuật toán dùng cho bài toán Phân loại (Classification), phổ biến nhất là phân loại nhị phân. Đối với bài toán nhiều lớp, thường sử dụng hàm Softmax.

- Cách mô hình quyết định: Đối với ngữ liệu, class nào xác suất cao nhất thì chọn lớp đó.
- Đối với bài toán này, các ngữ liệu sẽ được vector hoá bằng TF-IDF trước khi đưa vào mô hình logistic.

Phân tích kết quả và nhận xét:

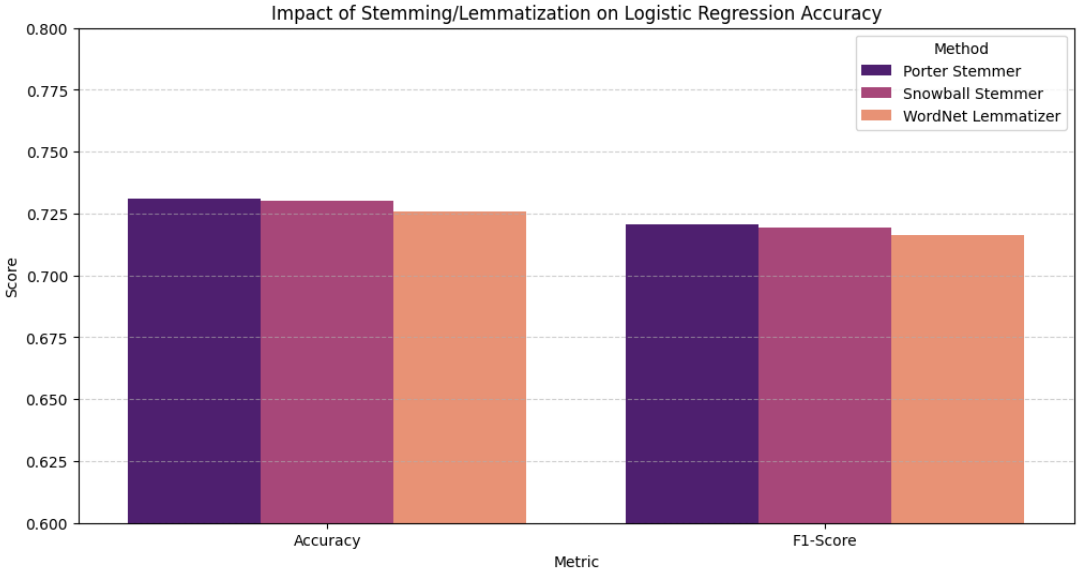

Hình 6: Kết quả Logistic Regression

Dựa trên việc đánh giá bộ dữ liệu 20newsgroups bằng Hồi quy Logistic (Logistic Regression), **Snowball Stemmer mang lại hiệu suất tốt nhất** với Độ chính xác (Accuracy) xấp xỉ 0.7296 và chỉ số Macro F1 là 0.7191.

- Các chỉ số hiệu suất: Ba kỹ thuật chuẩn hóa mang lại kết quả rất giống nhau: Snowball Stemmer đạt được Độ chính xác cao nhất (0.7309) và chỉ số Macro F1 (0.7205). Porter Stemmer theo sát phía sau với Độ chính xác và chỉ số F1 thấp hơn rất nhỏ. WordNet Lemmatizer cho kết quả thấp nhất trong ba phương pháp, với Độ chính xác là 0.726 và chỉ số F1 là 0.7162.

- Tác động của chuẩn hóa: Đối với tác vụ cụ thể này (phân loại 20newsgroups với TFIDF và Hồi quy Logistic), việc stemming mạnh (Snowball) đã chứng minh được hiệu quả hơn một chút so với phương pháp lemmatization dựa trên từ điển.

Kết luận: Stemming cắt bỏ hậu tố dựa trên quy tắc, trong khi **Lemmatization** truy xuất từ điển để tìm dạng gốc chính xác. Lemmatization có tỷ lệ va chạm (Collision rate) thấp hơn (0,06 so với 0,2), giúp bảo toàn nghĩa tốt hơn. Tuy nhiên, Snowball Stemmer lại cho độ chính xác cao nhất trong mô hình Logistic Regression thực tế. *Hướng phát triển:* Nghiên cứu kết hợp cả hai kỹ thuật (Hybrid approach) để tận dụng tốc độ của Stemming và độ chính xác của Lemmatization.

1.4.5 Vector hóa văn bản và phân tích không gian đặc trưng

Các kĩ thuật vector hóa Vector hoá văn bản: là quá trình chuyển đổi văn bản thành không gian vector (danh sách số) để máy tính có thể hiểu và tính toán được. Các kỹ thuật phổ biến bao gồm Bag-of-Words, TF-IDF hoặc các mô hình Word Embedding hiện đại như Word2Vec, BERT.

Số chiều: là số lượng đặc trưng của một vector, biểu diễn mức độ phức tạp của mô hình vector hoá. Ví dụ, TF-IDF với bộ từ điển 10000 từ thì số chiều sẽ là 10000.

Độ thưa(Sparsity Ratio): Là tỷ lệ giữa số lượng phần tử có giá trị bằng 0 so với tổng số phần tử trong ma trận (tập hợp các vector của văn bản). Các phương pháp như

BoW hay TF-IDF sẽ có ma trận rất thưa (độ thưa rất cao) vì số từ trong một văn bản chiếm tỉ lệ rất nhỏ trong toàn bộ từ điển.

Độ tương đồng Cosine (Cosine Similarity): Đây là một đại lượng dùng để đo lường mức độ giống nhau giữa hai vector bằng cách tính cosin của góc giữa chúng. t-SNE (t-distributed Stochastic Neighbor Embedding): là một kỹ thuật giảm số chiều phi tuyến tính, không giám sát, thường được dùng để đưa dữ liệu từ không gian cao chiều (ví dụ 10000 chiều) về 2 chiều (ở lab này) để trực quan hóa.

Chỉ số Silhouette (Silhouette Score): Đây là một đại lượng dùng để đánh giá chất lượng của việc phân cụm. Nó đo lường xem một điểm dữ liệu có nằm gần các điểm dữ liệu cùng cụm so với khác cụm hay không.

Ý nghĩa:

- Gần 1: phân cụm tốt vì điểm cùng cụm nằm sát nhau.
- Gần 0: phân cụm kém vì điểm nằm giữa các cụm.
- Gần -1: Điểm có thể đã bị gán sai cụm.

Các kĩ thuật vector hoá:

- **Bag of words**: là một kỹ thuật trích xuất đặc trưng mô hình hóa dữ liệu văn bản để xử lý trong NLP. Cụ thể hơn, mô hình BoW là một tập hợp không cấu trúc của tất cả các từ đã biết trong một tài liệu văn bản theo tần suất mà nó xuất hiện, mà bỏ qua thứ tự từ và ngữ cảnh. BoW là phương pháp vector hoá cổ điển và đơn giản nhất.

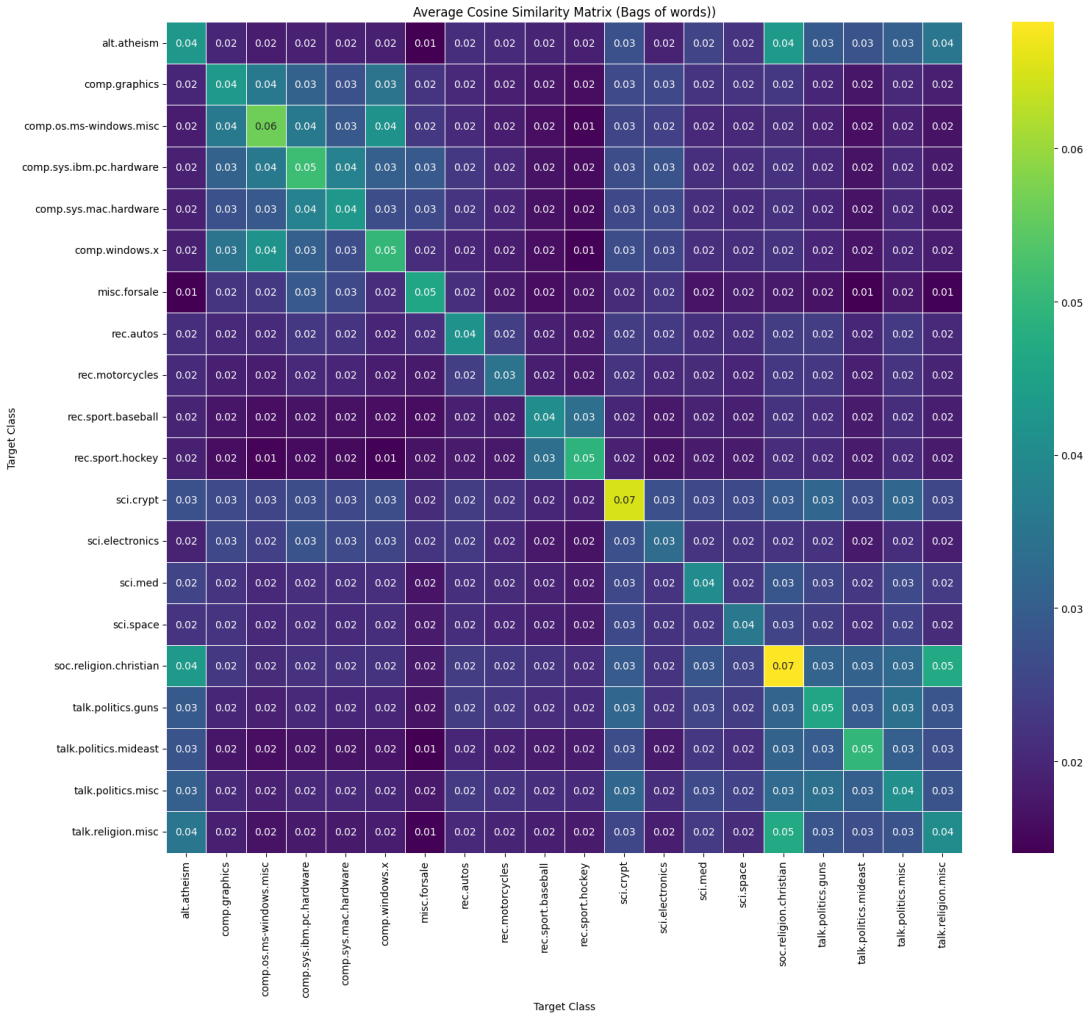

Hình 7: Consine similarity đối với Bag of words

- **TF-IDF**: là một phương pháp thống kê đo lường tầm quan trọng của một từ trong một văn bản trong một tập hợp nhiều ngữ liệu. Việc đếm số từ đơn giản có thể gây hiểu nhầm vì nhiều từ xuất hiện nhiều trong mọi văn bản (stop-word), nhưng TF-IDF gán tầm quan trọng cao hơn cho những từ xuất hiện thường xuyên trong một phân lớp văn bản trong khi vẫn hiếm gặp trong toàn bộ tập dữ liệu. Điều này làm cho nó hữu ích trong việc xác định các từ ngữ đại diện cho phân lớp văn bản đó. TF-IDF kết hợp với n-gram,một tập hợp gồm n từ liên tiếp trong một văn bản, có thể bao gồm từ, số, ký hiệu. Mô hình n-gram hữu ích trong nhiều ứng dụng phân tích văn bản, nơi chuỗi từ có liên quan, chẳng hạn như trong phân tích cảm xúc, phân loại văn bản và tạo văn bản.

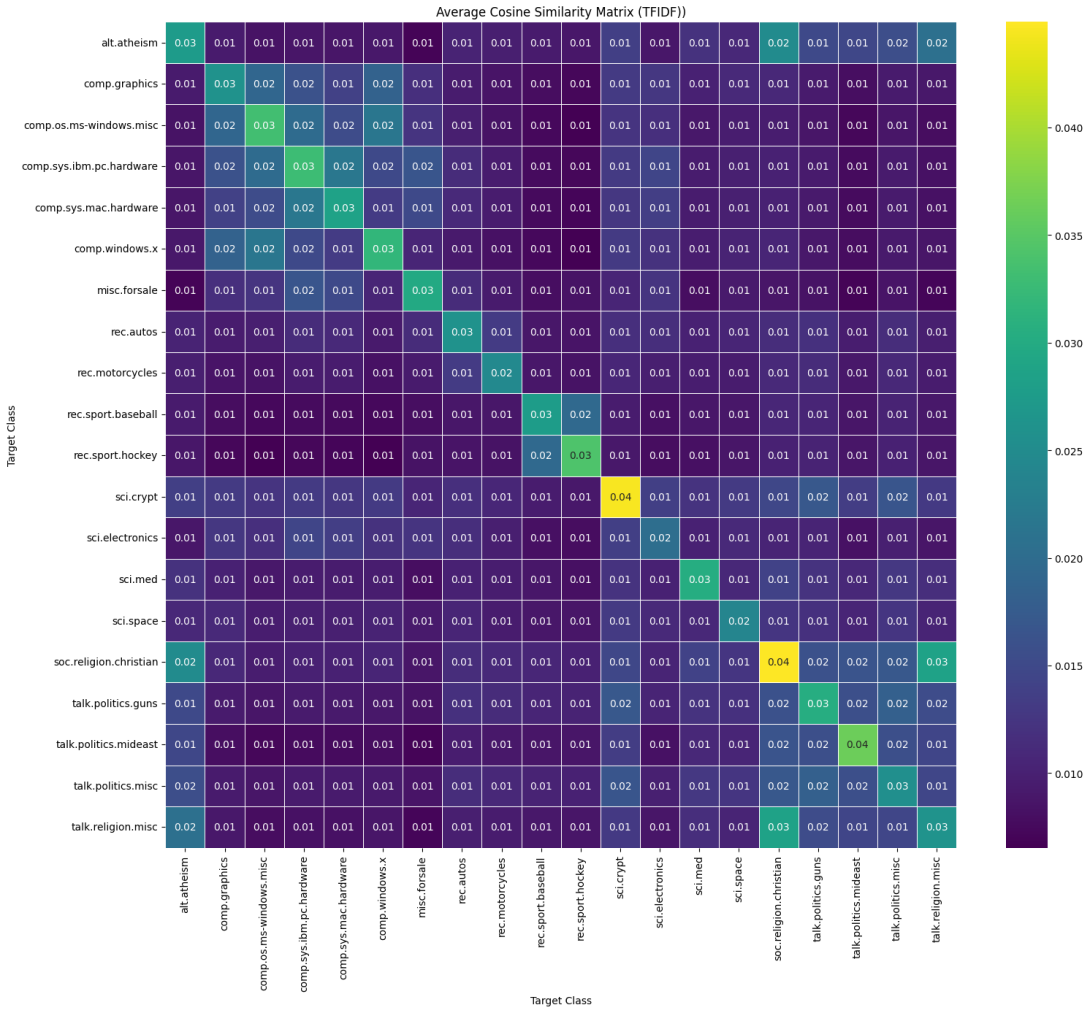

Hình 8: Consine similarity đối với TF-IDF

- **Word2Vec**: Word2vec là một mô hình đơn giản và nổi tiếng giúp tạo ra các biểu diễn embedding của từ trong một không gian có số chiều thấp hơn nhiều lần so với số từ trong từ điển. Mô hình đặt các từ có nghĩa tương tự gần nhau hơn trong không gian vectơ, cho phép máy móc hiểu được các mối quan hệ, sự tương đồng và ngữ cảnh.

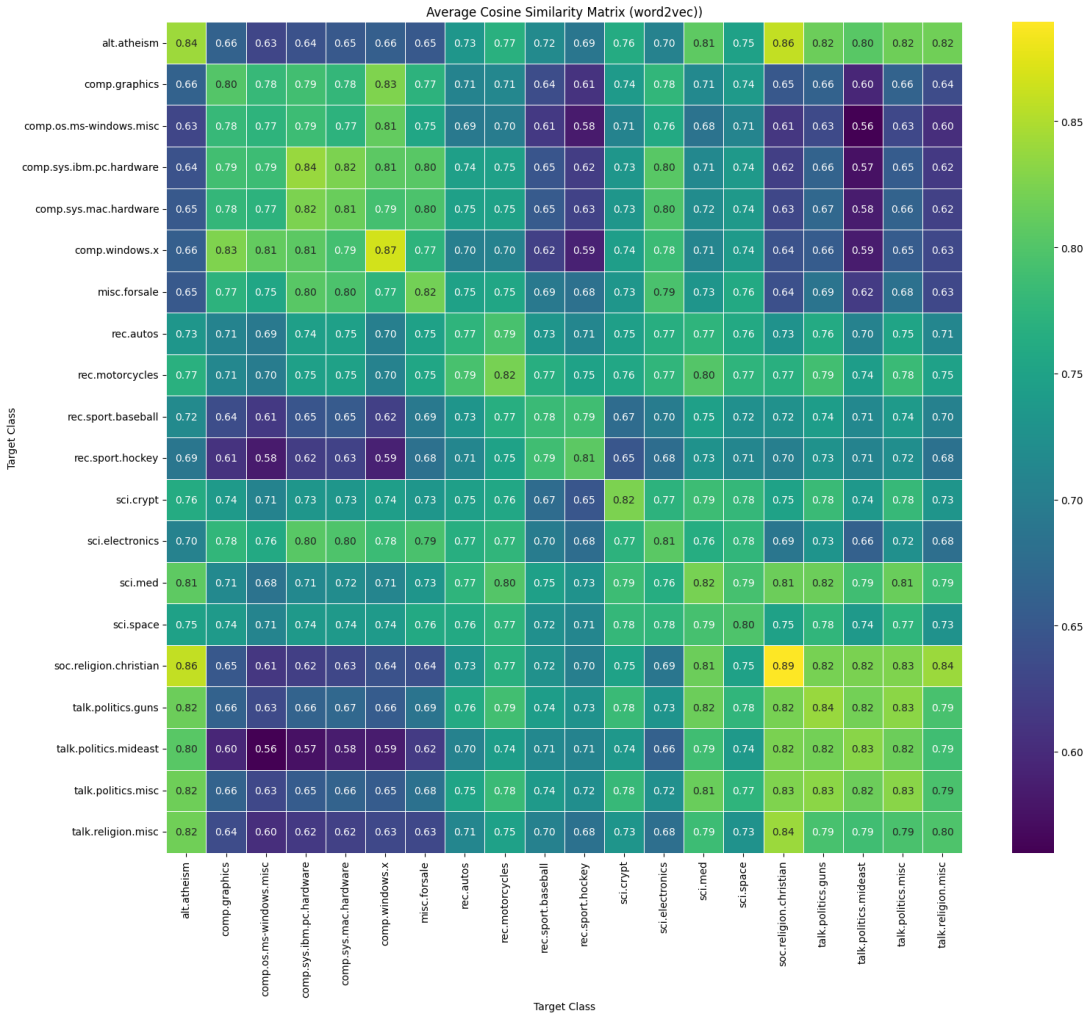

Hình 9: Consine similarity đối với Word2Vec

Phân tích kết quả: Bảng dưới đây tóm tắt đặc điểm của các không gian vector được tạo ra:

Bảng 2: So sánh đặc trưng giữa các phương pháp vector hóa.

Phương pháp	**Số chiều**	**Độ thưa**	**Silhouette Score**
Bag-of-Words	10.000	0.9952	-0.1935
TF-IDF	10.000	0.9949	-0.0006
Word2Vec	100	0.9900	-0.0388

Kết quả Cosine Similarity:

- Độ tương đồng Cosine trong BoW khoảng từ 0.02 đến 0.07, trong TF-IDF từ 0.01 đến 0.04, tuy nhiên trong **Word2Vec lại rất cao** (từ 0.4 đến 0.8). Điều này là hiển nhiên xét tới bản chất các phương pháp.
- BoW và TF-IDF thường có số chiều rất lớn (ở đây là 10000 chiều). Trong một không gian khổng lồ như vậy, các vector có xu hướng dạt ra xa nhau. Xác suất để hai văn bản khác nhau (dù cùng chủ đề) cùng chọn trúng những từ giống hệt nhau là rất

thấp. Trong khi đó, Word2Vec chỉ có khoảng 100 chiều, tạo ra sự chen chúc và làm cho độ tương đồng Cosine cao hơn rất nhiều.

- *Tỉ lệ số 0*: BoW và TF-IDF có độ thưa rất lớn, tức đa số giá trị của vector là số 0. Để tử số trong công thức Cosine khác 0, hai văn bản bắt buộc phải có từ trùng nhau. Nếu không trùng từ nào, similarity bằng 0 tuyệt đối. Còn trong Word2Vec, hầu hết các phần tử đều là số thực khác 0 . Ngay cả khi hai từ chẳng liên quan gì nhau, tích của các số thực này khi cộng dồn lại vẫn thường tạo ra một giá trị nhất định, khiến similarity hiếm khi bằng 0.

- *Khả năng hiểu nghĩa*: Với 2 từ đồng nghĩa (ví dụ: male và man), BoW và TF-IDF xem đó là 2 từ khác nhau -> độ tương đồng cộng thêm 0. Trong khi Word2Vec được học rằng 2 từ đó gần nghĩa nhau -> cộng thêm một giá trị gần 1.

- Đối với cả 3 phương pháp, độ tương đồng Cosine trong **cùng phân lớp luôn cao hơn** so với khác phân lớp. BoW và TF-IDF có độ khác biệt khoảng 1.5 đến 3 lần, còn Word2Vec thì khoảng 1.1 - 1.2 lần.

Silhouette Score:

- Cả 3 phương pháp đều có **Silhouette Score không lớn hơn 0**, chứng tỏ khả năng phân cụm là khá kém. Điều này là dễ hiểu vì bộ dữ liệu 20newsgroups có tới 20 phân lớp và độ đa dạng về từ vựng quá lớn, dẫn đến khả năng phân cụm bằng các phương pháp truyền thống không hiệu quả. Vì vậy, đối với bộ dữ liệu này, ta cần các phương pháp trích xuất đặc trưng hiện đại hơn (như BERT).

- Silhouette Score của **BoW là thấp nhất**, chứng tỏ cấu trúc phân cụm vốn có trong biểu diễn Bag-of-Words, được xác định bởi các nhãn mục tiêu, thiếu độ chặt chẽ và khả năng phân tách. TF-IDF và Word2Vec chỉ khá hơn một chút, do đã xét tới các yếu tố ngữ nghĩa (độ đặc trưng của từ trong phân lớp / các từ đồng nghĩa).

Kết luận: Tổng kết lại, các phương pháp vector hoá văn bản truyền thống như BoW, TF-IDF và kể cả Word2Vec đều chưa thể phân tách hiệu quả 20 chủ đề phức tạp của bộ dữ liệu 20newsgroups, thể hiện rõ qua sự chồng lấn mạnh mẽ trên biểu đồ t-SNE và chỉ số Silhouette âm. Mặc dù Word2Vec ưu việt hơn trong việc nắm bắt ngữ nghĩa so với BoW/TF-IDF, nhưng cả ba đều thiếu khả năng phân cụm một cách hiệu quả. Điều này khẳng định rằng tính đa dạng và sự giao thoa nội dung của tập dữ liệu này đòi hỏi những kỹ thuật trích xuất đặc trưng chuyên sâu và hiện đại hơn (như BERT) để có thể biểu diễn chính xác ranh giới giữa các phân lớp. *Hướng phát triển:* Thử nghiệm các phương pháp giảm chiều dữ liệu phi tuyến tính khác như UMAP để cải thiện khả năng phân tách cụm.

1.4.6 Biểu diễn ngữ nghĩa bằng Sentence Transformer

Sentence Transformer (SBERT): là một framework dựa trên kiến trúc BERT, được thiết kế đặc biệt để tạo ra các sentence embeddings (vector biểu diễn câu) có ý nghĩa về mặt ngữ nghĩa.

- *Bản chất*: Thay vì lấy trung bình các vector từ (như Word2Vec) hoặc dùng token [CLS] của BERT thuần túy, SBERT sử dụng cấu trúc Siamese Network để huấn luyện. Mạng Siamese có nghĩa là mỗi lần hai câu được truyền độc lập qua cùng một mô hình BERT. Sau khi xử lý một câu qua BERT, một lớp gộp (pooling layer) được áp dụng cho các embedding của BERT để có được biểu diễn có chiều thấp hơn: 512 vectơ 768 chiều ban đầu được chuyển đổi thành một vectơ 768 chiều duy nhất.

- *Mục tiêu*: Đảm bảo rằng hai câu có ý nghĩa giống nhau sẽ được ánh xạ vào hai vector có khoảng cách gần nhau trong không gian đa chiều. Điều này đảm bảo hiệu quả cho các tác vụ so sánh độ tương đồng (Cosine Similarity) hoặc tìm kiếm ngữ nghĩa.
- **Pretrained Sentence Transformer**: à các mô hình Sentence Transformer đã được huấn luyện sẵn trên các tập dữ liệu khổng lồ (như Wikipedia, Reddit,...). Ta chỉ cần tải về và sử dụng các vector của nó, như all-MiniLM-L6-v2.

Ở đây, em sử dụng hai thuật toán để đánh giá là K-means (phân cụm không giám sát) và Linear SVM (support vector machine - phân lớp có giám sát) để so sánh hiệu suất SBERT và TF-IDF trên 2 tập dữ liệu: data đã qua tất cả bước tiền xử lý ở trên và data chỉ xử lý bước a (bỏ qua tokenization, stemming, loại bỏ stop word).

Bảng 3: Hiệu suất của SBERT so với TF-IDF trên dữ liệu thô và đã tiền xử lý.

Dữ liệu	**Phương pháp**	**K-means (Silh)**	**Acc (SVM)**	**F1-score (SVM)**
Đã tiền xử lý	TF-IDF	-0.0082	**0.7309**	**0.7227**
	SBERT	**0.0498**	0.6580	0.6409
Văn bản thô	TF-IDF	-0.0095	0.6668	0.6585
	SBERT	**0.0567**	**0.7114**	**0.6982**

Phân tích và diễn giải kết quả: *Phân cụm:*

- **SBERT vượt trội hoàn toàn**: Trong cả hai trường hợp (có hoặc không tiền xử lý), SBERT đều cho chỉ số Silhouette dương, trong khi TF-IDF luôn âm.
- SBERT tạo ra không gian vector dựa trên ngữ nghĩa, giúp các tài liệu cùng chủ đề tập hợp lại về mặt khoảng cách toán học tốt hơn so với việc chỉ đếm từ của TF-IDF.

Phân loại:

- *Khi có Tiền xử lý (Stemming, loại bỏ Stop Word)*: **TF-IDF thắng** (0.73 so với 0.65). Khi ta đưa từ về gốc (stem) và loại bỏ từ dừng, các từ khóa trở nên sắc nét hơn, giúp mô hình phân loại (SVM) dễ dàng tìm thấy ranh giới. Ngược lại, các bước đó làm hỏng cấu trúc câu tự nhiên, khiến SBERT mất đi thông tin ngữ cảnh và ngữ nghĩa quan trọng.
- *Khi để Văn bản thô (Raw text)*: **SBERT thắng** (0.71 so với 0.66). SBERT được huấn luyện trên ngôn ngữ tự nhiên rất lớn và đa dạng. Nó đủ thông minh để hiểu ngữ cảnh ngay cả khi có từ dừng hay các dạng của từ khác nhau. Ngược lại, TF-IDF lúc này bị nhiễu bởi quá nhiều từ biến thể, làm giảm độ chính xác.

Kết luận: TF-IDF vẫn là một công cụ vector hóa mạnh mẽ cho NLP nếu các văn bản được tiền xử lý một cách đầy đủ (tokenization, stem, lemma, remove stop words). Tuy nhiên, các công cụ hiện đại như SBERT đã được huấn luyện một cách phức tạp trên ngôn ngữ tự nhiên thuần tuý, giúp tăng hiệu suất các tác vụ, đặc biệt là không giám sát (như Clustering) trên tập dữ liệu thô. Nếu muốn cải thiện thêm, việc sử dụng văn bản thô kết hợp với SBERT cho mọi tác vụ để tận dụng tối đa sức mạnh ngữ cảnh của Deep Learning là điều không thể tránh khỏi trong thời đại LLM bùng nổ như hiện tại. *Hướng phát triển:* Fine-tune mô hình SBERT với hàm mất mát chuyên biệt (Triplet loss) trên tập dữ liệu này để tăng cường độ chặt chẽ của các cụm nội dung.

1.4.7 Kết luận chung

Trên đây là toàn bộ các bước tiền xử lý văn bản, bao gồm chuẩn hoá, tokenization, loại bỏ stop words, stemming / lemmatization và vector hoá. Mỗi bước bao gồm các phương pháp khác nhau, từ cổ điển đến hiện đại. Thực nghiệm cho thấy rằng, không có phương pháp nào là hoàn hảo, chúng đều phải đánh đổi để đạt được kết quả mong muốn, ví dụ đánh đổi thời gian để đạt được độ chính xác cao. Vì vậy, việc lựa chọn phương pháp tiền xử lý nào không phụ thuộc vào bản thân phương pháp, mà phải dựa vào bản chất dữ liệu, kết quả mong muốn (hiệu suất hay độ chính xác) và bản chất của vấn đề cần giải quyết (vì tiền xử lý chỉ là bước đầu cho một quy trình mô hình hoá giải quyết bài toán). Việc thực nghiệm và đưa ra các chỉ số đánh giá cụ thể là bước hết sức cần thiết để xác định nhu cầu phù hợp cho bài toán cần xử lý.

Notebook trên Colab: Link